DietSense：對話式每日熱量攝取 Domain AI Agent

期末專題提案（Final Project Proposal）

> 本文件依《期末專題提案作業規範》的順序撰寫：Abstract、Introduction、Related Work、Deep Research、Proposed Scheme、References。 內容由 GitHub repository 的 `docs/` 與 `openspec/` 自動合成（`scripts/build_docs.py`）。Repository：https://github.com/A0966411725-png/dietsense-proposal 目前是 Proposal 階段：沒有程式碼，也沒有實驗結果；所有成效都是預期目標。

1. Abstract

飲食自我記錄是行為體重管理的核心策略，但記錄負擔讓多數人難以持續。WHO 指出 2022 年全球逾 8.9 億成人肥胖；台灣 2017–2020 年國民營養調查顯示，約一半成人體重高於建議範圍。然而 2026 年的範疇回顧發現，熱量 App 的記錄頻率在第 4 至 12 週間由每週 5.4 天降至 1.4 天。現有工具要求使用者搜尋品項、估計份量並拆解複合料理，對台灣小吃支援不足；拍照 App 與大型語言模型雖然方便，照片估熱量的誤差約 36%，珍珠奶茶等混合飲品甚至低估達 76%，數值也無法追溯來源。

為解決上述問題，本專題提出 DietSense 對話式熱量攝取 Domain AI Agent。使用者用一句中文描述飲食，LLM 負責意圖分類、食物抽取與任務規劃；營養數值則錨定於食藥署資料庫、自建台式料理庫與 USDA FoodData Central，再以份量對照表與 Mifflin-St Jeor 公式進行確定性計算。系統以熱量區間取代單一數字，信心不足時最多追問一次，並設有安全守門機制避免助長過度節食。

評估上，本研究將建立 500 筆台式料理標註集，與純 LLM 估算及手動查詢比較 MAE、±20% 命中率、區間覆蓋率、記錄時間、SUS 與安全攔截率，並進行 20 人 7 天使用者研究。預期 DietSense 的準確度優於純 LLM、記錄時間短於手動查詢、SUS 高於 70；以上皆為預期目標，實際成效將依實驗結果報告。

摘要的 A–F 結構

段落	內容	用到的核心 / 取捨 / 細節
A. Attention	WHO：2022 年全球 25 億成人過重，其中逾 8.9 億人肥胖 [R14]；台灣 2017–2020 成人過重加肥胖，男性約 58%、女性約 43% [R15]；成人 68% 平均每天至少外食一餐（19–44 歲達 84%）[N4]；拍照記熱量 App Cal AI 兩年安裝逾 1,500 萬、被 MyFitnessPal 收購 [N3]	C1
B. But	App 記錄頻率在 12 週內大幅下降 [R11]；MyFitnessPal 使用者漏記約 18% 的品項 [R13]；GPT-4o 照片估熱量 MAPE 約 36% [R3]；四個熱門拍照 App 每餐少算 250–345 kcal（NUTRITION 2026，初步結果）[N2]；AI App 把珍珠奶茶的熱量低估最多 76% [N1]；中式料理 benchmark 的最佳模型 MAPE 仍有 24% [R5]	C1、C2
C. Cure	提出 DietSense 對話式熱量攝取 Domain AI Agent：讓使用者用語言補充照片看不到的資訊（油、湯、份量）	C3
D. Development	LLM function calling Planner + 台灣優先的多來源 RAG + 份量對照表 + Mifflin-St Jeor + 區間量化 + 安全守門；完整設計見 design.md	C3–C5、T1–T3、細節 1–9

段落	內容	用到的核心 / 取捨 / 細節
E. Experiments	500 筆標註集（必含珍奶、湯麵、燴飯等高誤差類別，並分類別回報誤差）、兩種基準、六類指標、20 人 7 天研究、30+ 筆安全測試	細節 10
F. Findings（Expected）	預期 ±20% 命中率優於純 LLM 基準、區間 coverage ≥ 80%、每餐記錄時間低於手動查詢、SUS > 70、安全攔截率 100%；學術產出為台式料理 benchmark 與區間校準結果。**這些是規劃目標，不是實驗結果。**	C4、C5

2. Introduction

A. Attention Getter（A2Z：G. General）

肥胖已是全球性的慢性病問題。WHO 指出，2022 年全球有 25 億成人過重，其中逾 8.9 億人肥胖，而且全球肥胖盛行率在 1990–2022 年間增加超過一倍 [R14]；2025 年 12 月，WHO 首度發布 GLP-1 藥物治療肥胖的指引，並提到全球肥胖人口已超過 10 億 [R21]。台灣也不例外：2017–2020 年國民營養健康狀況變遷調查顯示，成人男性過重 30.31%、肥胖 28.12%，女性過重 22.98%、肥胖 19.57% [R15]，也就是約一半的成人體重高於建議範圍。

藥物之外，飲食自我記錄是行為體重管理的核心策略：系統性回顧一致發現，自我記錄與減重顯著相關 [R24]。問題在於，**人們做不到持續記錄**。

B. Background（A2Z：G. General）

- **應用領域**：個人營養與體重管理，屬於 Health Informatics。
- **使用者**：台灣成人，三餐以外食為主（便當、小吃、夜市、手搖飲），通常不會秤重，只會用「一碗」、「一份」、「半杯」描述。國民營養調查顯示，19 歲以上成人有 68.0% 每週外食 7 次以上，19–44 歲更達 83.7%，只有 11.4% 的成人完全不外食 [N4]。外食正是份量與油脂最難掌握的情境。
- **市場**：低負擔記錄的需求很明確。拍照記熱量 App Cal AI 兩年內安裝超過 1,500 萬次，2026 年被 MyFitnessPal 收購 [N3]；但同類 App 的準確度仍有明顯問題（見 C. Problem）。
- **技術背景**：大型語言模型已能理解這類口語描述，多模態模型也能辨識照片中的食物 [R2][R4]；同時，Agent 架構可以讓 LLM 透過 function calling 查詢外部資料庫，把回答錨定在可信資料上 [R6][R10]。這讓「用一句話記錄一餐」在技術上變得可行。

C. Problem（A2Z：H. However）

本專題要解決的問題是：**如何讓台灣使用者用最少的力氣記錄飲食，同時得到有來源、誠實呈現不確定性、而且安全的熱量分析？**

這個問題可以拆成四個具體障礙：

1. **查詢負擔**：要在上萬筆品項中搜尋正確名稱。
2. **份量模糊**：日常生活不會秤重，只有「一碗」、「一份」。
3. **複合料理**：一碗牛肉麵包含麵、湯、肉、蛋，需要拆解。
4. **在地資料不足**：台灣小吃與熟食在常用資料庫中覆蓋不足 [R22][R23]。

證據顯示這些障礙會直接造成放棄：熱量 App 的記錄頻率在第 4 到 12 週間，由每週約 5.4 天降到 1.4 天 [R11]；即使有記錄，使用者也平均漏記約 18% 的品項，而且能量明顯被低估 [R13]。改用拍照也沒有解決問題：AI App 對混合料理特別不準，把珍珠奶茶的熱量低估最多 76% [N1]；美國 NIDDK 團隊在 2026 年的初步結果也顯示，四個熱門拍照 App 平均每餐少算 250–345 kcal，主要是看不到油脂 [N2]。

D. Existing Limitations（A2Z：I. In literature → J. Judgement）

現有方法	優點	限制（附證據）
手動資料庫 App（MyFitnessPal 等）	能量與巨量營養素有可接受的相對效度 [R12]	負擔高、持續度快速下降 [R11]；使用者自建資料品質不一；台灣小吃少
影像 MLLM 直接估算	拍照即可，負擔低	GPT-4o 熱量 MAPE 約 35.8% [R3]；與營養師一致性只有中等（ICC 0.31–0.67）[R2]；中式料理最佳 MAPE 仍有 24.45% [R5]
商業拍照 App（Cal AI 等）	下載量大，市場接受度高	每餐少算 250–345 kcal、脂肪少算約 30 g（初步結果）[N2]；珍奶低估最多 76% [N1]
文字 LLM 直接估算	輸入最自然	最佳模型的碳水估算準確率約 67%，不同國家的餐點誤差差距很大 [R1]；數字沒有來源，可能有幻覺
資料錨定 Agent	數字可追溯	現有研究以美國或歐洲資料庫為主 [R6][R10]；缺台灣熟食；較少處理對話與安全

判斷：沒有任何一類方法同時做到「低負擔、可追溯、在地化、誠實呈現不確定性、具安全機制」。

E. Innovation（A2Z：K. Keypoint）

DietSense 和現有系統的不同之處：

1. **分工**：LLM 只負責理解語言與規劃，營養數值全部來自資料庫與公式，所以每個數字都能追溯。
2. **台灣優先**：檢索順序以食藥署資料庫與自建台式料理庫為先，USDA 補足其他食物。台灣團隊的研究已顯示，加入在地食物知識的客製化 GPT-4o，食物辨識率由 59% 提升到 74% [R4]。
3. **用語言補足照片看不到的資訊**：油、湯喝多少、加了什麼料，都可以用一句話說明，正好對應拍照 App 最大的誤差來源 [N2]。
4. **誠實的不確定性**：以熱量區間取代單一數字，並用 coverage 與寬度兩個指標一起校準，避免用過寬的區間灌水。
5. **有上限的追問**：每項食物最多追問一次，在準確度與負擔之間取得平衡（Trade-off T1）。
6. **安全守門**：用完整日或 7 日資料判斷攝取過低，避免早餐後就誤報，並拒絕極低熱量計畫。

F. Contributions

1. **系統**：一個可運作的繁體中文對話式熱量攝取 Domain AI Agent（DietSense），附 OpenSpec 規格與 DESIGN.md。
2. **資料**：一套 500 筆台式料理自然語言描述標註集，包含參考熱量、份量重量與來源。
3. **評估框架**：涵蓋準確度（MAE、MAPE、±10%/±20%）、不確定性（coverage、寬度）、效率（記錄秒數、追問率）、可用性（SUS）與安全（攔截率、誤報率），並與純 LLM、手動查詢兩種基準比較。
4. **錨定管線**：一套整合食藥署資料庫、台式料理庫與 USDA 的檢索與排序流程，可供後續研究重用。

L. List the organization（文章結構）

本提案其餘章節安排如下：第二章 Related Work 依 AI 技術與營養領域知識兩部分回顧文獻，並整理 Article Summary Table 與 Research Gap；第三章 Deep Research 回答五個核心思維、三個專業爭論與十個深度問題；第四章 Proposed Scheme 以 ①–⑧ 模組說明系統架構、流程圖、虛擬碼與技術可行性；第五章說明實驗設計與預期成果；第六章為結論與未來工作。

3. Related Work

M. Methods：AI Technology（約 1/2）

M1. 從文字估營養：LLM 直接估算

NutriBench [R1]（ICLR 2025）用 11,857 筆由真實飲食調查資料產生的自然語言餐點描述，評估 12 個 LLM 估算碳水化合物的能力。表現最好的 GPT-4o 搭配 CoT，準確率（誤差在 ±7.5 g 內）為 66.8%；作者也請 3 位營養師估算同一批樣本，LLM 的準確度相當或更高，而且快得多。有三個發現和 DietSense 直接相關：

1. GPT-4o 與 GPT-4o mini 在克數描述（「80 g 飯」）上，比在自然份量描述（「一杯飯」）上準。
2. RAG 不一定提升準確率。
3. 不同國家的餐點誤差差距很大：GPT-4o + CoT 的 MAE 最低 2.20 g、最高 15.12 g。

意義：文字估算可行，但口語份量與在地食物仍是弱點；而且「加上檢索就會變準」不是理所當然，必須實測（見 Trade-off T2）。

M2. 從照片估營養：多模態 LLM

- O'Hara et al.（2025）[R2]：ChatGPT-4 辨識照片中食物的精確度約 93%，但熱量、蛋白質、碳水估算與 7 位營養師的一致性只有中等（ICC 0.31–0.67）。
- Fridolfsson et al.（2025）[R3]：52 張標準化照片，GPT-4o 和 Claude 3.5 Sonnet 的熱量 MAPE 都約 35.8%，Gemini 1.5 Pro 約 64.2%。
- Chen et al.（2025，台灣，AJCN）[R4]：客製化的 Diabot-GPT-4o 在 57 人、714 張照片上，只用影像的食物辨識率為 74%，未客製化的 GPT-4o 為 59%；熱量大致落在秤重記錄的 ±10–20% 內。**意義**：加入領域客製化（台灣食物知識）能明顯提升表現。
- DiningBench（ACL 2026）[R5]：3,021 道菜，其中 2,086 道為中式料理；表現最好的模型營養估算平均 MAPE 仍有 24.45%，作者把誤差歸因於無法從 2D 推斷 3D 份量。
- Lo et al.（2024）[R8]：用穿戴式相機拍攝的半自由生活飲食資料測試 GPT-4V。模型不需微調就能辨識食物；加上語言提示（例如指定料理類型）後能辨識地區性料理，也能用周圍物品當比例尺推估份量。**意義**：語言提示可以補足影像，和 DietSense「用一句話補充資訊」的想法一致。
- Coburn et al.（2025）[R9]：提出 ACETADA 資料集並評估 8 個多模態模型。把地點、時間與食物項目等情境資訊寫進提示，可以降低熱量、巨量營養素與份量估算的 MAE 與 MAPE。**意義**：餐別與用餐情境值得記錄。

M3. 資料錨定與 Agent 化（新趨勢）

- ChatDiet（2024）[R7]：LLM + 個人模型 + 族群模型 + orchestrator，可以產生個人化、可解釋的飲食推薦；但只用一位使用者的三年資料做個案研究。
- 斯洛維尼亞食品成分 RAG 評估（2026）[R10]：在斯洛維尼亞食品成分資料庫上建立 RAG，比較 4 個 LLM（Gemini、GPT、Claude、Mistral）把自然語言查詢轉成檢索條件的能力。簡單與中等難度的查詢準確度高，條件無法用欄位表達的困難查詢則不可靠。**意義**：把國家資料庫接到 LLM 的做法已有先例，但尚未延伸到對話式記錄。

- Open-KNEAD（2026）[R6]：把餐點拆解成單項，再錨定到 USDA FNDDS 代碼，屬於 training-free 的 Agent 框架。作者也發現，新一代 MLLM 直接估算已能追上甚至超過完整檢索管線。**意義**：這是對 DietSense 的重要反證，所以我們把「純 LLM」列為必測基準（見 Trade-off T2）。

M. Methods：Domain Know-how（約 1/2）

D1. 能量平衡與 TDEE

體重變化來自長期的能量不平衡，而且身體會動態適應，不能用「每 7,700 kcal = 1 kg」線性推算 [R18]。TDEE 估算採用 Mifflin-St Jeor 公式 [R17]，它在一般成人上是常用的實務選擇。**設計影響**：缺口分析以區間和趨勢呈現，不宣稱精確減重預測。

D2. 自我記錄的效果與誤差

- 自我記錄和減重有一致的正相關 [R24]，但持續度會快速下降 [R11]。
- 自我報告本身就有系統性誤差，尤其是低報 [R19]。
- MyFitnessPal 在能量與巨量營養素上有可接受的相對效度 [R12]，但使用者平均漏記約 18% 的品項，而且能量明顯被低估 [R13]。**設計影響**：降低每次記錄的負擔，比把單次估算做到極致更能改善整體資料品質。

D3. 食物成分資料與台灣在地性

台灣的官方來源是食藥署「台灣地區食品營養成分資料庫」[R22]，以原料與初級加工食品為主，複合熟食料理很少；USDA FoodData Central [R23] 涵蓋廣，但缺乏台灣小吃。**設計影響**：需要自建台式料理庫，以食材拆解計算營養，並標示資料來源與衍生方式。

D4. 品質 vs. 數量、個人化 vs. 通用指引

- DIETFITS 隨機試驗 [R20]：健康低脂與健康低碳飲食在 12 個月的減重成效沒有顯著差異，支持「總熱量與飲食品質」比單一巨量營養素比例重要。
- Zeevi et al. [R16]：同一種食物在不同人身上的血糖反應差異很大，支持精準個人化；但需要血糖監測與腸道菌資料，超出一般使用情境。**設計影響**：以每日飲食指南與 AMDR 等通用指引作為安全基線，不做醫療層級的個人化。

D5. 公共衛生背景

WHO 指出 2022 年全球有 25 億成人過重，其中逾 8.9 億人肥胖 [R14]；2025 年 WHO 在 GLP-1 用藥指引中提到全球肥胖人口已超過 10 億 [R21]。台灣 2017–2020 年國民營養調查顯示，成人男性過重 30.31%、肥胖 28.12%；女性過重 22.98%、肥胖 19.57%（過重定義為 $24 \leq \text{BMI} < 27$，肥胖為 $\text{BMI} \geq 27$）[R15]。

O. Organize：Article Summary Table

共 14 篇：AI 技術 8 篇（R1–R7、R10），營養與行為領域 6 篇（R11–R13、R19、R20、R24）。

Ref	Year	Problem	AI Method	Domain Knowledge	Dataset	Findings	Limitation
[R1] Hua et al.	2025	從餐點文字估碳水	12 個 LLM、CoT、RAG 等提示策略	全球飲食攝取調查資料、營養標註	NutriBench，11,857 筆描述	GPT-4o + CoT 準確率約 66.8%	以碳水為主；非中文、非台灣食物
[R2] O'Hara et al.	2025	照片估營養是否可取代營養師	ChatGPT-4（多模態）	營養師估算作為比較	114 張餐點照片（38 張與營養師比較）	食物辨識精確度約 93%；與營養師 ICC 0.31–0.67	樣本小；一致性只有中等
[R3] Fridolfsson et al.	2025	比較三個 LLM 從照片估重量與熱量	GPT-4o、Claude 3.5 Sonnet、Gemini 1.5 Pro	秤重參考值	52 張標準化照片	熱量 MAPE：GPT-4o 35.8%、Claude 35.8%、Gemini 64.2%	照片標準化，與真實情境有落差；沒有資料錨定
[R4] Chen et al.（台灣）	2025	客製化 GPT-4o 能否提升影像飲食評估	客製化 Diabot-GPT-4o vs. GPT-4o	秤重飲食記錄、台灣飲食	57 人、714 張照片、171 天	食物辨識 74% vs. 59%；熱量多在 ±10–20%	受試者為營養系學生；需要拍照
[R5] DiningBench	2026	飲食領域的感知與推理 benchmark	多個 MLLM	中式料理營養標註	3,021 道菜（中式 2,086）	最佳模型營養估算 MAPE 24.45%	只有影像；作者指出文化偏向中式料理
[R6] Open-KNEAD	2026	錨定食品資料庫的營養估算	Agentic decomposition + FNDDS 錨定	USDA FNDDS 代碼	餐點影像 benchmark	錨定可得到逐項紀錄；新一代 MLLM 直接估算已追上檢索管線	以美國食品代碼為主
[R7] Yang et al.（ChatDiet）	2024	個人化營養推薦聊天機器人	LLM + 因果個人模型 + orchestrator	營養成分族群模型	1 人 3 年穿戴裝置資料	推薦測試有效率 92%	n = 1；不是熱量記錄
[R10] Požarnik Vavken et al.	2026	LLM 能否把自然語言查詢轉成食品成分資料庫的檢索條件	4 個 LLM（Gemini、GPT、Claude、Mistral）+ RAG	斯洛維尼亞食品成分資料庫	依難度分級的查詢	簡單與中等難度查詢準確度高	困難查詢不可靠；預印本；不是對話式記錄
[R11] Dugas et al.	2026	熱量計數 App 的使用與持續度	（回顧研究）	行為體重管理	2013–2024 的研究	MyFitnessPal 記錄頻率在第 4–12 週由每週 5.4 天降到 1.4 天	範疇回顧，沒有合併效果量
[R12] Evenepoel et al.	2020	MyFitnessPal 資料庫算出的營養值是否準確	（無；商用 App 資料庫）	比利時食品成分資料庫 Nubel	50 人，兩次 4 天飲食記錄	能量 r = 0.96，碳水、脂肪、蛋白質 r = 0.90；膽固醇與鈉相關性弱	受試者事先接受詳細指導；比利時食物
[R13] Chen et al.	2019	自然情境下用 App 記錄飲食是否準確	（無；人工記錄 App）	24 小時回憶法、食物類別編碼	成人 4 天 MyFitnessPal 記錄 vs. 2 天 24 小時回憶	平均漏記 18% 品項（多為高熱量、低營養食物）；能量低估 1,863 kJ	非台灣族群；樣本為澳洲成人

Ref	Year	Problem	AI Method	Domain Knowledge	Dataset	Findings	Limitation
[R19] Poslusna et al.	2009	飲食記錄與 24 小時回憶法的誤報有多嚴重	（無；文獻回顧）	食物記錄、24 小時回憶法	37 篇研究	約 30% 的受試者是低報者；能量約低估 15%	回顧的是紙本與訪談方法，未涵蓋 App
[R20] Gardner et al.（DIETFITS）	2018	健康低脂與健康低碳飲食，哪個減重效果好	（無；隨機試驗）	巨量營養素組成、基因型、胰島素分泌	609 位過重成人，12 個月	兩組減重沒有顯著差異	美國族群；不是熱量記錄研究
[R24] Burke et al.	2011	自我記錄和減重有沒有關聯	（無；系統性回顧）	行為減重的飲食、運動、體重自我記錄	22 篇研究（15 篇為飲食記錄）	自我記錄與減重一致呈顯著相關	證據等級偏弱；樣本多為白人女性、依賴自報

方法分類比較（A2Z 的 J. Judgement / O. Organize）

方法類別	準確度	使用者負擔	可追溯性	台灣在地性	主要缺點
手動資料庫 App（MyFitnessPal 等）	中高（依使用者）	**高**	中（使用者自建資料品質不一）	低	搜尋、秤重、拆解很累 → 放棄
影像 MLLM 直接估算 [R2–R5]	中（MAPE 24–36%）	低	**低**	低到中	看不出份量與隱藏油脂；數字無來源
文字 LLM 直接估算 [R1]	中	**低**	**低**	低	最佳模型碳水準確率約 67%；不同國家的餐點誤差差距大；數字無來源
錨定 / RAG Agent [R6] [R10]	中高	低到中	**高**	依資料庫而定	錨定資料庫缺台灣熟食；多半只處理單次估算
DietSense（本專題）	目標：中高（待驗證）	低（最多一次追問）	**高**	**高**（台灣優先）	需要自建料理庫；只支援文字

N. New proposed：Existing Research → Limitations → Research Gap → Our Project

Existing Research	Limitations	Research Gap	Our Project（DietSense）
LLM / MLLM 直接估營養 [R1–R5]	MAPE 24–36%；數字沒有來源	**G1** 缺少「好用」又「可追溯」的估算方式	LLM 只負責理解；數值錨定到資料庫並附來源
資料錨定 Agent [R6][R10]	以美國或歐洲資料庫為主；缺台灣熟食	**G2** 缺少台灣在地的錨定資料	食藥署資料庫優先 + 自建台式料理庫
現有研究多回報單一點估計	使用者看不出估算有多不確定	**G3** 缺少不確定性的呈現與校準	熱量區間 + coverage / 寬度校準
記錄 App 的持續度與誤差研究 [R11][R13]	負擔高導致放棄；也缺安全機制	**G4** 缺少兼顧低負擔與飲食安全的對話式流程	單次追問 + 安全守門（7 日規則、拒絕極低熱量）

4. Deep Research

Q1. 五個核心思維

1. 能量平衡（Energy Balance）是動態的，不是線性的

- **意義**：體重變化來自攝取與消耗的長期差距；但身體會隨體重下降而降低消耗，所以不能用「少吃 7,700 kcal 就瘦 1 公斤」直線推算。
- **證據**：Hall 等人（2011）的動態模型指出，能量不平衡對體重的影響需要考慮代謝適應 [R18]；Hall 等人（2016）在代謝病房讓 17 位男性改吃等熱量的生酮飲食，體脂下降並沒有加快，能量消耗只小幅增加約 57 kcal/天（代謝艙測量）[R26]。
- **對系統設計的影響**：⑤ 分析引擎以「區間 + 7 日趨勢」呈現缺口，不提供精確的減重日期預測。

2. 巨量營養素組成（Macronutrient Composition）

- **意義**：同樣的熱量，蛋白質、碳水、脂肪的比例會影響飽足感、身體組成與長期健康。
- **證據**：美國 AMDR 建議碳水 45–65%、蛋白質 10–35%、脂肪 20–35%；國健署每日飲食指南的規劃原則較窄：醣類 50–60%、蛋白質 10–20%、脂質 20–30% [R28]。
- **對系統設計的影響**：`energy-analytics` 以**台灣每日飲食指南**為主要比較基準，AMDR 作為較寬的參考範圍；輸出一定附巨量營養素比例，不只報總熱量。

3. 份量估算是最大的誤差來源，必須量化不確定性

- **意義**：同一道菜的份量差異遠大於資料庫數值的差異，而使用者通常低報。
- **證據**：Poslusna 等人（2009）回顧 37 篇研究，約 30% 的受試者是低報者，能量攝取平均約低估 15% [R19]；拍照 App 每餐少算 250–345 kcal，主要是看不到脂肪 [N2]。
- **對系統設計的影響**：每筆記錄輸出 low / point / high 區間，區間寬度隨配對信心與份量描述的模糊程度變寬（design.md 的 `w` 公式）。

4. 個體差異（Individual Variation）

- **意義**：同樣的食物在不同人身上的代謝反應不同。
- **證據**：Zeevi 等人（2015）發現，同一種食物引起的餐後血糖反應在不同人之間差異很大，個人化模型的預測優於通用規則 [R16]。
- **對系統設計的影響**：收集性別、年齡、身高、體重、活動量來計算個人 TDEE；但**不做**需要血糖或腸道菌資料的醫療級個人化（Trade-off T3）。

5. 飲食行為受情境影響（Behavioral Context）

- **意義**：壓力、情緒、睡眠與社交場合都會改變飲食，單看熱量無法理解行為。
- **證據**：Koenders 與 van Strien（2011）追蹤 1,562 位員工，發現情緒性進食（而不是生活型態因素）是 BMI 增加的穩定預測因子，運動可以減弱這個關聯 [R27]。

- **對系統設計的影響**：日誌記錄用餐時間與餐別；`dietary-safety-guard` 偵測暴食-節食交替模式，用非評判的語氣提示，而不是只算熱量。

Q2. 三個最重要的專業爭論

結構：觀點 A ↔ 觀點 B → Evidence → Consensus → Unresolved → 對 DietSense 的影響

爭論一：熱量數量 vs. 食物品質（A calorie is a calorie?）

	觀點 A：熱量就是熱量	觀點 B：食物組成會改變代謝
主張	只要總熱量相同，巨量營養素比例對體重影響不大	低碳飲食會降低胰島素、提高能量消耗（碳水-胰島素模型）
最強證據	DIETFITS：609 位成人，健康低脂與健康低碳 12 個月減重沒有顯著差異 [R20]；Hall 2016：等熱量生酮飲食沒有加快體脂下降 [R26]	Ebbeling 2018：164 位成人減重後維持期，低碳（20%）組的總能量消耗比高碳（60%）組多約 209 kcal/天（意向治療分析）[R25]

- **目前共識**：長期熱量不足是減重的必要條件；食物品質影響飽足感、可持續性與健康指標。
- **尚未解決**：Ebbeling 的能量消耗差異能否重現、是否只出現在胰島素分泌高的人身上。
- **對 DietSense 的影響**：同時顯示熱量與巨量營養素比例；建議以「總熱量 + 飲食品質」為主，不推銷特定飲食法。

爭論二：AI 估算份量與熱量，夠不夠準？

	觀點 A：AI 已足夠日常使用	觀點 B：AI 還不夠準
主張	新模型的準確度接近或超過營養師，適合日常追蹤	份量、隱藏油脂、混合料理的誤差仍大，數字也無法追溯
最強證據	客製化 GPT-4o 的熱量多在秤重記錄 ±10–20% 內 [R4]；新一代 MLLM 直估已追上檢索管線 [R6]；NutriBench 中 LLM 的碳水估算與 3 位營養師相當或更準，而且快得多 [R1]	GPT-4o 照片估熱量 MAPE 約 36% [R3]；中式料理最佳 MAPE 24.45% [R5]；珍奶低估最多 76% [N1]；拍照 App 每餐少算 250–345 kcal [N2]

- **目前共識**：AI 適合趨勢追蹤，不適合臨床精確計算；誤差集中在份量、油脂與混合料理。
- **尚未解決**：資料錨定在新一代模型上是否仍有優勢（NutriBench 發現 RAG 不一定提升準確率 [R1]）；如何讓使用者理解不確定性。
- **對 DietSense 的影響**：熱量以區間呈現；純 LLM 列為必測基準；高誤差類別分項評估。

爭論三：通用指引 vs. 高度個人化

	觀點 A：通用指引是安全基線	觀點 B：精準個人化才有效
主張	DRI、每日飲食指南適用大多數人，安全、可解釋	基因、腸道菌、代謝決定最佳飲食，需要個人化
最強證據	Bilen 2026：5 個 AI 聊天機器人替過重青少年排的菜單，平均每天比營養師少約 695 kcal [N5]——缺少安全基線的「個人化」可能有害	Zeevi 2015：個人化血糖預測模型優於通用建議 [R16]

- **目前共識**：通用指引是安全基線，個人化是優化方向，兩者不互斥。

- **尚未解決**：AI 個人化建議的法律責任（是否構成醫療建議）與資料隱私。
- **對 DietSense 的影響**：分層設計——通用指引與安全下限一定生效；個人資料只用於 TDEE；明確的非醫療聲明（`dietary-safety-guard`）。

Q3. 十個深度理解問題（附 DietSense 的回答）

#	類型	問題	DietSense 的回答重點	設計位置
1	Why	為什麼吃一樣多熱量的兩個人，一個瘦了、一個沒有？Agent 如何避免給所有人同樣的建議？	代謝適應與個體差異（Q1-1、Q1-4）；用個人 TDEE 與 7 日趨勢，而不是固定數字	energy-analytics
2	What-if	使用者只說「吃了一碗泡麵」，沒說品牌、加蛋、湯喝多少，Agent 怎麼辦？	信心 < 0.80 時只問一個最影響熱量的問題（通常是湯）；其餘不確定性反映在區間寬度（沒有份量描述時，半寬比例多 0.15）	conversational-food-logging、design 符號與參數
3	Trade-off	問越多越準、但越煩；怎麼找平衡點？用什麼指標衡量？	每項最多追問一次（T1）；同時量測追問率、每餐記錄秒數、±20% 命中率、7 日持續記錄天數	agent-evaluation、design Decision 4
4	Failure Case	資料庫裡沒有的食物（例如眷村阿嬤的炒年糕），如何優雅降級？	追問後信心仍低於 0.50，就依食材拆解估算，標示「近似估算」並加寬區間；每 100 g 的數值仍來自資料庫，不報錯也不假裝精確	nutrient-retrieval、design Decision 9
5	Evidence	有什麼證據支持 AI 輔助記錄比傳統日記有效？若要做 RCT 怎麼設計？	證據：持續記錄與減重正相關 [R24]，負擔是放棄主因 [R11]。RCT：隨機分派 DietSense vs. 傳統 App，主要結果為 12 週持續記錄天數，次要結果為體重與 SUS	docs/02、tasks 7
6	Comparison	RAG LLM、微調領域 LLM、知識圖譜 + 規則引擎，各適合什麼條件？	RAG：資料常更新、需要來源；微調：大量標註資料、追求語言流暢；知識圖譜：規則明確、需要可解釋推理。DietSense 用 RAG + 規則表	design Decision 2
7	Design Decision	為什麼選對話式 Agent？什麼情況下對話反而比傳統 UI 差？	外食、混合料理、口語份量適合對話；但重複吃同樣早餐時，一鍵「再記一次」比對話快——列為 Future Work	docs/02-E
8	Real-world	珍奶、雞排、蚵仔煎在 USDA 幾乎沒有，怎麼建立、維護、驗證台灣在地資料？	食藥署資料庫為原料基礎，自建台式料理庫以食材拆解計算並標示來源；≥ 50 筆雙人獨立標註、≥ 30 筆與業者營養標示比對	nutrient-retrieval、agent-evaluation
9	Why	Harris-Benedict、Mifflin-St Jeor、Katch-McArdle 各有什麼假設？哪些人會失準？	Mifflin-St Jeor 以健康成人建立 [R17]；對運動員（肌肉量高）、高齡者、孕婦、慢性病患可能失準。Agent 選用 Mifflin-St Jeor，並在回應中說明它是估計值	energy-analytics
10	What-if	如果 Agent 長期建議 < 1,200 kcal，反而助長飲食失調，該怎麼設計？	下限依性別區分（女 1,200 / 男 1,500 kcal [R29]），以完整日或 7 日平均判斷、拒絕低於下限的菜單、偵測暴食-節食交替、提供轉介；AI 菜單過低的風險有實證 [N5]	dietary-safety-guard

5. Proposed Scheme

5.1 設計核心：5 個核心、3 個取捨、10 個細節

#	核心	一句話說明	落在哪一段
C1	**問題：記錄太累，所以沒人持續記錄**	飲食自我記錄有效，但 App 使用率在 12 週內從每週約 5.4 天降到 1.4 天 [R11]	A、B
C2	**缺口：好用的不準，準的不好用**	手動 App 準但耗時、資料庫有使用者自建的錯誤 [R12][R13]；純 LLM 好用但熱量 MAPE 約 36% 且無來源 [R3]	B
C3	**解法：LLM 只理解語言，數字交給資料庫與公式**	DietSense = 對話式 Planner + 台灣優先的多來源營養資料錨定 + 確定性計算	C、D
C4	**誠實：以區間取代單一數字**	每筆熱量輸出 low / point / high，並附上來源；信心不足時最多追問一次	D、F
C5	**安全：工具不能助長過度節食**	用完整日或 7 日資料判斷攝取過低，拒絕極低熱量計畫，並提供轉介資訊	D、E

#	取捨	我們的選擇	代價與如何量測
T1	**準確度 vs. 使用者負擔**：追問越多越準，但越容易放棄	信心 < 0.80 才追問，每項食物**最多一次**，不足的部分加寬區間	區間會變寬；用「追問率」、「每餐記錄秒數」、「±20% 命中率」一起評估
T2	**資料錨定（RAG）vs. LLM 直接估算**	以資料錨定為主，LLM 不產生數值	台式熟食在資料庫覆蓋不足，需要自建料理庫；Open-KNEAD（2026）指出新一代 MLLM 直接估算已接近檢索管線 [R6]，NutriBench 也發現 RAG 不一定提升準確率 [R1]，所以把「純 LLM」列為基準方法實測，不預設一定比較差
T3	**個人化 vs. 安全與可解釋**	TDEE 用 Mifflin-St Jeor + 依性別的安全下限，不做基因或血糖個人化	個人化程度較低 [R16]；換來的是可說明、可驗證、不越權給醫療建議

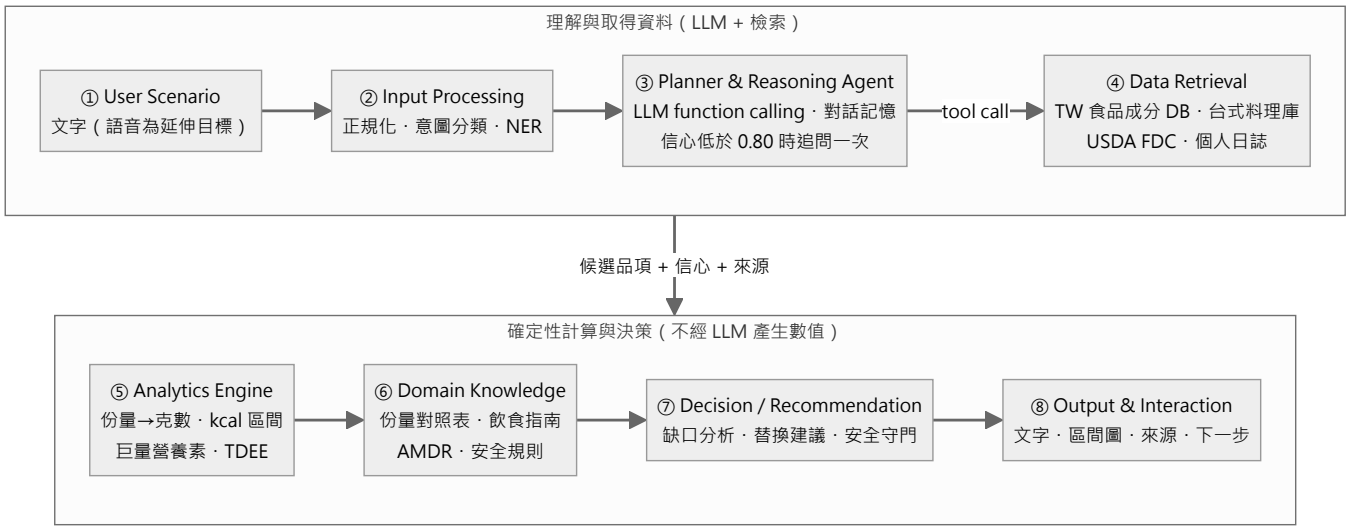
1. **意圖四分類**：`log_food`、`query_nutrition`、`analyze`、`recommend`；判斷不出來就回問，不猜測。
2. **實體結構**：食物名稱 + 份量描述 + 加料 / 修飾詞（例如「湯喝一半」）+ 餐別。
3. **檢索順序**：食藥署食品營養成分資料庫 → 自建台式料理庫（向量檢索）→ USDA FoodData Central。
4. **信心門檻 τ = 0.80**：低於門檻才追問；追問後仍低於 0.50，就改用食材拆解並標示「近似估算」。兩個門檻都是初始值，W6 用評估集校準。
5. **區間公式**：半寬比例 w = 0.10 + 0.50·(1 − 信心) + 0.15·份量模糊度，上限 0.60。份量模糊度：有克數為 0、家用單位（碗、份、杯）為 0.5、沒有份量為 1。每日總量的半寬以平方和開根號合併。
6. **份量對照表**：碗、份、個、杯、片依食物類別換算成克數（例如麵類一碗與飯類一碗不同）。
7. **TDEE**：Mifflin-St Jeor BMR × 活動係數 1.2–1.9；缺少資料就詢問，不用預設值 [R17]。
8. **巨量營養素**：以國健署每日飲食指南為主（醣類 50–60%、蛋白質 10–20%、脂質 20–30%），AMDR 為參考範圍 [R28]。
9. **安全規則**：下限依性別區分（女 1,200 / 男 1,500 kcal [R29]）；當日結算後或 7 日平均低於下限才警示；拒絕低於下限的菜單請求；偵測暴食-節食交替。
10. **評估設計**：500 筆台式料理標註集；基準為純 LLM（Base 與 CoT 兩種提示）與手動資料庫查詢；指標為 MAE、MAPE、±10%/±20% 命中率、區間 coverage、記錄秒數、SUS、安全攔截率；使用者研究 20 人 × 7 天。

5.2 Agent 的行為需求

行為需求寫成 OpenSpec 規格，每個 Requirement 都有可測試的 Scenario（WHEN / THEN）。

Capability	Requirement	Scenario 數
`agent-evaluation`	台式料理標註資料集	1
`agent-evaluation`	參考值驗證	2
`agent-evaluation`	高誤差類別分項報告	1
`agent-evaluation`	基準方法比較	2
`agent-evaluation`	區間校準度	1
`agent-evaluation`	安全測試集	1
`conversational-food-logging`	意圖分類	3
`conversational-food-logging`	食物實體抽取	2
`conversational-food-logging`	有上限的澄清追問	2
`conversational-food-logging`	記錄可修改	1
`dietary-safety-guard`	以完整日或多日資料判斷攝取過低	2
`dietary-safety-guard`	依性別設定安全下限	2
`dietary-safety-guard`	拒絕不安全的限制請求	1
`dietary-safety-guard`	暴食-節食循環提示	1
`dietary-safety-guard`	非醫療聲明	1
`energy-analytics`	熱量以區間呈現	3
`energy-analytics`	巨量營養素比例	1
`energy-analytics`	個人 TDEE	2
`energy-analytics`	缺口分析與替換建議	2
`nutrient-retrieval`	多來源錨定與優先順序	2
`nutrient-retrieval`	數值來源可追溯	1
`nutrient-retrieval`	未知食物降級處理	1
`nutrient-retrieval`	營養查詢不寫入日誌	1
`nutrient-retrieval`	資料來源失敗時的降級	1
合計	**24 個 Requirement**	**37**

5.3 System Architecture（①–⑧）



#	模組	輸入 → 輸出	對應 spec
①	User Scenario	使用者訊息、個人資料	conversational-food-logging
②	Input Processing	原始文字 → `{intent, entities[]}`	conversational-food-logging
③	Planner & Reasoning	intent + 對話狀態 → 工具呼叫計畫 / 澄清問題	conversational-food-logging
④	Data Retrieval	食物名稱 → 候選品項 + 信心 + 來源	nutrient-retrieval
⑤	Analytics Engine	品項 + 份量 → kcal(low, point, high)、巨量營養素、TDEE	energy-analytics
⑥	Domain Knowledge	規則與對照表（確定性資料，不經 LLM）	energy-analytics、dietary-safety-guard
⑦	Decision	每日狀態 → 建議或安全提示	energy-analytics、dietary-safety-guard
⑧	Output	結構化結果 → 自然語言 + 圖表 + 來源	全部

模組逐一說明

① User / Application Scenario：使用者是三餐以外食為主的台灣成人，用一句繁體中文描述剛吃的東西，或詢問「今天吃了多少」、「晚餐還能吃什麼」。第一次使用時填寫性別、年齡、身高、體重與活動量。系統不要求秤重，也不要求拍照。

② Query / Input Processing：先做確定性的正規化（繁簡、全半形、「半碗」→ 0.5 碗），再用一次 LLM 結構化輸出同時完成意圖四分類與實體抽取，輸出固定的 JSON schema：`{intent, entities[{name, portion, modifiers[], meal}]}`。LLM 回傳的 JSON 不合 schema 時重試一次，仍失敗就回問使用者。

③ Planner & Reasoning Agent：這是 Agent 和一般聊天機器人不同的地方。Planner 依意圖決定要呼叫哪些工具、順序如何，並維護對話狀態（每項食物的 `asked` 旗標、尚未回答的澄清問題、缺少的個人資料）。它的決策只有三種：呼叫工具、問一個問題、進入輸出；它不產生任何營養數值。

④ Data Acquisition / Retrieval：四個資料來源。

- 食藥署「食品營養成分資料集」（離線匯入 SQLite）：原料與初級加工食品。
- 自建台式料理庫（向量索引）：每道菜記錄成分組成、每種成分的克數與對應的食藥署品項。
- USDA FoodData Central（API + 快取）：西式與包裝食品。
- 個人日誌（本機 SQLite）：當日記錄與近 7 日歷史。

每個候選品項都帶有配對信心 `c` 與來源識別碼。任一外部來源逾時，就略過該來源並在回應中註明。

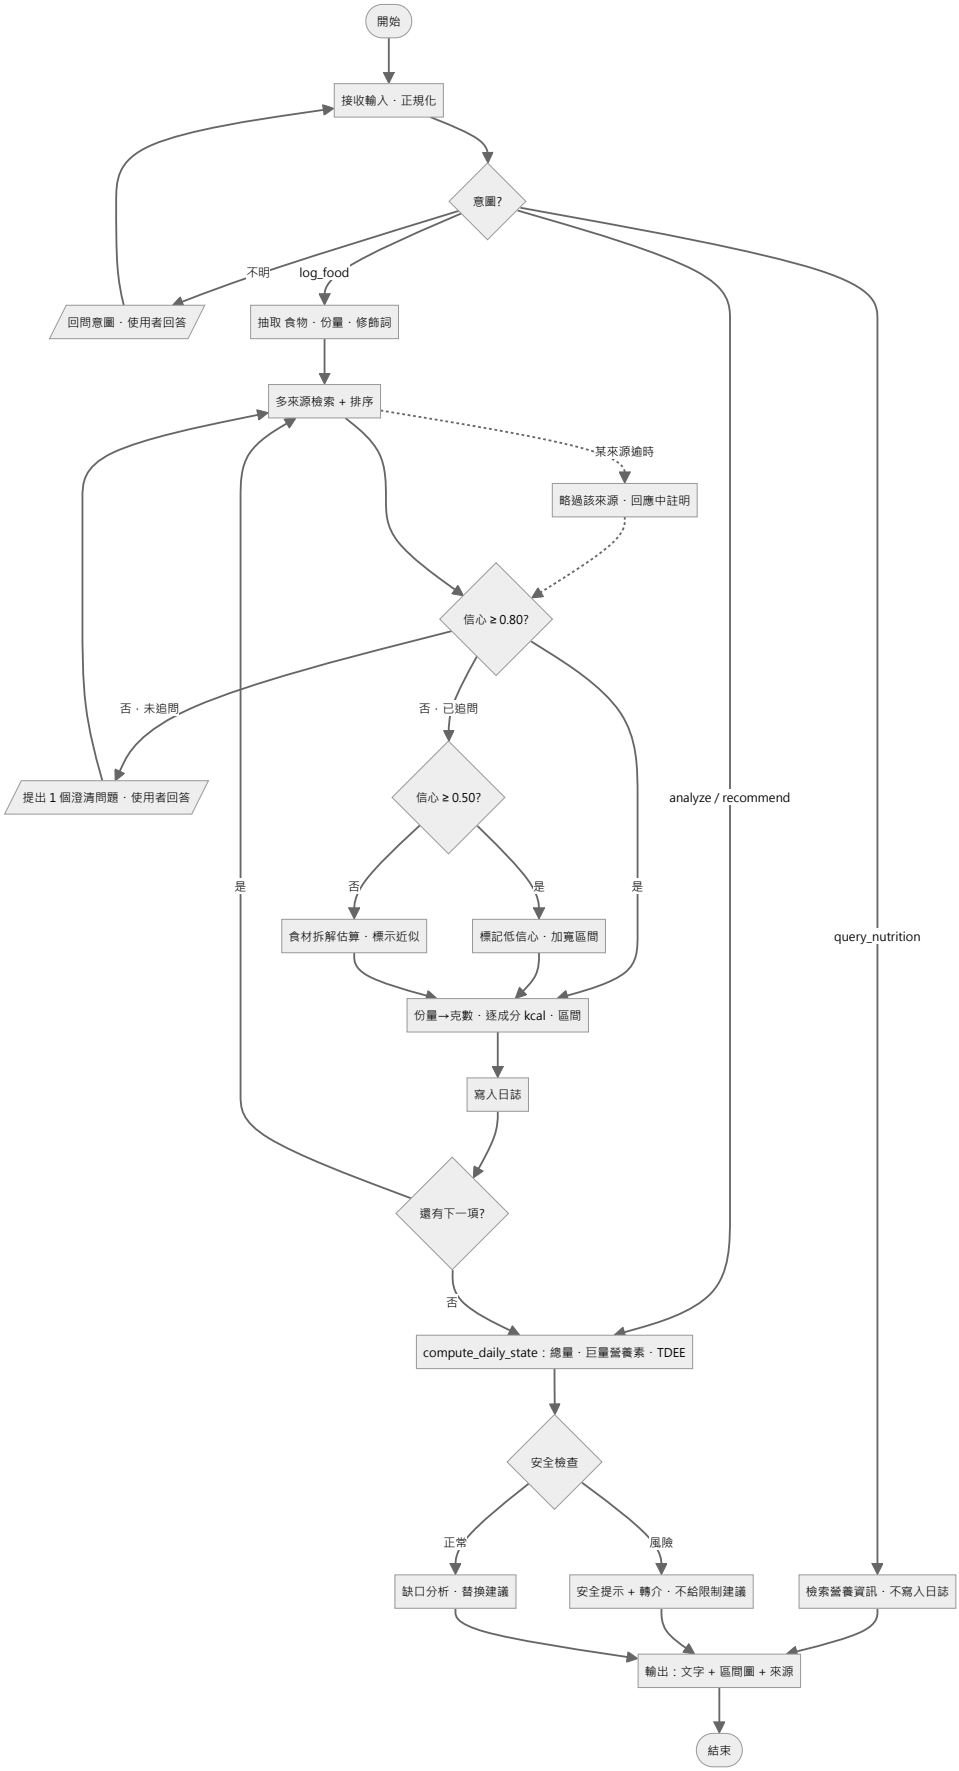
⑤ **Analytics Engine**：全部是確定性程式碼。把份量換成克數、逐成分加總熱量、計算區間半寬、三大營養素占比、BMR 與 TDEE，以及每日總量。同樣的輸入一定得到同樣的輸出，可以用單元測試驗證。

⑥ **Domain Knowledge Integration**：以表格與規則保存的營養專業知識，不經 LLM：份量對照表（依食物類別）、每日飲食指南與 AMDR 的三大營養素範圍、Mifflin-St Jeor 公式與活動係數、依性別的安全下限、暴食-節食模式的判斷規則。每條規則都有文獻或官方來源（見 docs/03 的 References）。

⑦ **Decision / Recommendation**：先做安全檢查，再決定能不能給建議。有風險時只輸出安全提示與轉介資訊；沒有風險且使用者要求分析或建議時，依「TDEE − 今日攝取」的差距與三大營養素占比，從料理庫挑出熱量較低或占比較均衡的替換選項。

⑧ **Output & Interaction**：回應固定包含四個部分：本次記錄的品項與熱量區間、今日累計與 TDEE 的比較、可展開的資料來源（資料庫 + 品項 ID），以及下一步（待回答的問題或建議）。區間用橫條圖呈現，低信心與「近似估算」的項目會另外標示。

5.4 Flowchart



流程圖包含規範提到的四種元素：

- **Decision**：意圖、信心 ≥ 0.80、信心 ≥ 0.50、還有下一項、安全檢查。
- **Loop**：逐項食物的迴圈；追問後重新檢索的迴圈（每項最多一次）。
- **Exception**：資料來源逾時、資料庫查無此物（食材拆解）、安全風險。
- **Human Interaction**：回問意圖、澄清問題。

5.5 Pseudocode

```
Algorithm 1: DietSense — Conversational Calorie Intake Agent
Input : user message Q, user profile P, daily log D, history H (7 days)
Output: response R, updated log D
01: q ← normalize(Q)                                        ▷ ② 繁簡、全半形、單位
02: (intent, ents) ← classify_and_extract(q)                ▷ ② LLM 結構化輸出；格式錯誤重試一次
03: if intent = UNKNOWN then return ask("要記錄這餐，還是查詢營養？"), D
04: if intent = query_nutrition then return render(lookup(ents), sources), D   ▷ 只查詢，不寫入日誌
05: if intent = log_food then
06:   for each e in ents do                                 ▷ 主項與加料各自成項
07:     C ← retrieve(e.name, [TW_FCD, TW_DISH, USDA_FDC])   ▷ ④ 逾時的來源略過
08:     (m, c) ← rank(C, e.context)                         ▷ c ∈ [0, 1]：配對信心
09:     if c < τ and not e.asked then                       ▷ τ = 0.80；Human interaction
10:       e ← update(e, ask(clarify(e, C))); e.asked ← true; goto 07
11:     if c < τ_low then m ← decompose_by_ingredients(e); e.approx ← true   ▷ τ_low = 0.50；Exception
12:     g ← portion_to_grams(e.portion, m, PORTION_TABLE)   ▷ ⑥ 例：麵類一碗
13:     k ← Σ_j g · share_j(m) · kcal_j / 100 · adj_j(e.modifiers)          ▷ ⑤ 逐成分加總；例：湯 adj = 0.5
14:     w ← min(w_max, w0 + α·(1 − c) + β·vagueness(e.portion))             ▷ 區間半寬比例
15:     D.add(m, g, (k(1−w), k, k(1+w)), source=m.id, conf=c, approx=e.approx)
16: S ← compute_daily_state(D, P)                           ▷ ⑤ 總量區間，巨量營養素，BMR，TDEE
17: risk ← safety_check(D, H, P, S, request=q)              ▷ ⑦ 完整日 / 7 日平均；依性別的下限
18: if risk ≠ OK then return render(alert(risk), sources=D), D
19: if intent ∈ {analyze, recommend} then rec ← recommend(S, P, KB) else rec ← ∅   ▷ ⑥⑦
20: return render(S, rec, sources=D, charts=intervals(D)), D                    ▷ ⑧
```

符號與參數

符號	定義	初始值
`c`	配對信心：名稱相似度（別名完全相符為 1，否則取向量相似度）與屬性一致性（食物類別、烹調法、份量單位是否相容）的加權。W6 用評估集校準，讓 `c` 接近「第一名候選正確的機率」	—
`τ`	追問門檻：`c < τ` 且尚未追問時，提出一個澄清問題	0.80
`τ_low`	降級門檻：追問後 `c` 仍低於此值，改用食材拆解並標示「近似估算」	0.50
`share_j(m)`、`kcal_j`	品項 `m` 第 `j` 個成分的重量占比，以及該成分每 100 g 的熱量。單一食材只有一個成分，占比為 1	料理庫
`adj_j`	修飾詞對成分 `j` 的調整倍率，例如「湯喝一半」讓湯的倍率為 0.5	1
`vagueness`	份量描述的模糊程度：有克數或包裝標示為 0；家用單位（碗、份、杯、顆）為 0.5；沒有份量、使用預設份量為 1	—
`w0`、`α`、`β`	區間半寬比例的基礎值、信心係數、份量係數	0.10、0.50、0.15
`w_max`	半寬比例上限，避免區間寬到沒有參考價值	0.60

BMR（Mifflin-St Jeor）：男 = 10W + 6.25H − 5A + 5；女 = 10W + 6.25H − 5A − 161；TDEE = BMR × 活動係數（1.2–1.9）。 每日總量：點估計直接相加；半寬以平方和開根號合併（見 Decision 8）。 以上數值都是初始值，W6 用評估集校準後更新。

5.6 端到端範例

> 下列熱量與信心都是**示意數值**，用來說明每個模組做什麼、公式怎麼算；實作後以資料庫的實際數值為準。

使用者（30 歲女性、165 cm、60 kg、活動係數 1.55；早餐已記錄 380 kcal）輸入：**「午餐吃了一碗加蛋的台式牛肉麵，湯喝一半」**

步驟	模組	發生什麼事
1	②	意圖 = `log_food`。抽取出兩項：台式牛肉麵（一碗；修飾詞：湯 50%）、蛋（一顆）；餐別 = 午餐
2	③④	牛肉麵配對到自建台式料理庫，`c = 0.86 ≥ 0.80`，不追問
3	③④	「蛋」可能是滷蛋或荷包蛋，`c = 0.72 < 0.80` → 追問一次：「加的是滷蛋還是荷包蛋？」使用者回答「滷蛋」→ 重新檢索，`c = 0.93`
4	⑤⑥	牛肉麵逐成分加總：麵 340 + 牛肉 160 + 湯 250 × 0.5 = **625 kcal**；滷蛋 **75 kcal**
5	⑤	牛肉麵 `w = 0.10 + 0.50 × 0.14 + 0.15 × 0.5 = 0.245` → 472–778 kcal；滷蛋 `w = 0.10 + 0.50 × 0.07 + 0.15 × 0.5 = 0.21` → 59–91 kcal
6	⑤	這一餐：點估計 700 kcal；半寬 = √(153² + 16²) ≈ 154 → **546–854 kcal**
7	⑤	每日狀態：今日累計 1,080 kcal（913–1,247）；BMR = 600 + 1,031 − 150 − 161 = 1,320；TDEE = 1,320 × 1.55 ≈ 2,046 kcal
8	⑦	安全檢查：當日尚未結算，不判斷攝取過低；近 7 日平均高於下限 → 正常
9	⑧	輸出：兩項的熱量區間、今日累計與 TDEE 的差距、來源（料理庫品項 ID、食藥署整合編號），並註明「滷蛋是依你的回答記錄的」

這個範例同時示範了三件事：修飾詞只調整對應的成分（湯）、一項食物只追問一次、合併後的區間比單項直接相加窄。

5.7 Technical Feasibility

資料與工具都已確認可取得（2026-11-11 查證）

項目	可行性依據	限制與對策
食藥署食品營養成分資料集	政府資料開放平臺資料集 8543；CSV、JSON、XML；政府資料開放授權條款第 1 版；每 3 個月更新；欄位含樣品名稱、俗名、每 100 克含量、每單位重	以原料為主，熟食少 → 自建台式料理庫
USDA FoodData Central	公開 API（`/foods/search`）；CC0 公有領域；每個 IP 每小時 1,000 次請求，需申請免費的 data.gov API key	有請求上限 → 查詢結果本機快取；評估時最多約 1,500 次查詢，分批執行
LLM（意圖、抽取、規劃）	結構化輸出與 function calling 是主流商用模型的標準功能；預設用小型模型，並以 adapter 介面抽換供應商	模型版本會變 → 評估時固定版本並記錄；JSON 不合 schema 時重試一次
向量檢索	料理庫只有數百筆，用多語言 embedding 加本機向量索引即可，不需要專用伺服器	別名（例如「珍奶」、「波霸奶茶」）→ 料理庫每筆記錄別名
後端與儲存	Python 3.11、FastAPI、SQLite；不需要 GPU	—

工作量估計

工作	估計	週次
台式料理庫 150 道（每道查食材、定份量、記來源）	每道約 20 分鐘，共約 50 小時	W2
評估集 500 筆（描述、參考熱量、來源）	每筆約 6 分鐘，共約 50 小時	W6
雙人標註 50 筆、業者標示比對 30 筆	約 10 小時	W6
LLM 呼叫量（評估）	500 筆 ×（DietSense 1–2 次 + 純 LLM 兩種提示）≈ 2,000–2,500 次	W6

以上是規劃用的估計值，不是量測結果。資料建置（約 110 小時）是時程上最大的風險。

如果進度落後，依序縮減

1. 語音輸入（本來就是 W8 延伸目標）。
2. 使用者研究由 20 人縮為 10 人，並在報告中說明。
3. 手動查詢基準只做 100 筆分層抽樣（規格已允許）。
4. 評估集由 500 筆縮為 300 筆；這會違反 `agent-evaluation` 的需求，必須先修改 spec 並在報告中說明。

安全守門（W5）與來源追溯（W4）不在縮減範圍內。

驗收方式

每一週的任務都對應到 spec 的 Scenario：W3–W5 以 Scenario 寫成自動化測試（意圖、抽取、區間、TDEE、安全規則）；W6 以評估腳本產出比較表；W7 以問卷與使用紀錄產出可用性結果。

5.8 Evaluation Protocol 與 Expected Outcomes

項目	做法
基準一：純 LLM	和 DietSense 相同的模型，不給資料庫，直接輸出熱量；Base 與 Chain-of-Thought 兩種提示都測（NutriBench 顯示 CoT 會明顯改善結果，只測 Base 對基準不公平）
基準二：手動查詢	一位沒有參與標註的操作者，用食藥署資料庫的查詢介面逐筆查詢並計時；至少 100 筆分層抽樣
準確度	MAE、MAPE、±10% 與 ±20% 命中率；整體與分類別都回報
區間	coverage（參考值落在區間內的比例）與平均半寬；初始目標 coverage ≥ 80%
統計	同一筆資料上的成對比較：命中率用 McNemar 檢定，誤差用成對 bootstrap 的 95% 信賴區間
使用者研究	20 人 × 7 天，受試者內交叉設計，使用順序平衡；記錄每餐秒數、追問率、持續記錄天數、SUS
研究倫理	書面知情同意、可隨時退出、資料去識別且只存本機；以篩選問卷排除未成年人、孕婦與有飲食失調病史者

Proposal 階段沒有實驗結果。以下是**預期目標**，W6–W7 完成後以實際結果取代：

- ±20% 命中率優於純 LLM 基準（Base 與 CoT）。
- 區間 coverage ≥ 80%，同時回報平均半寬。
- 每餐記錄時間短於手動查詢；SUS > 70。

- 安全測試集攔截率 100%，並回報誤報率。

5.9 設計決定與被放棄的替代方案

1. **LLM 當 Planner，不當計算器**：數值全部由 ④⑤⑥ 的確定性程式碼產生。
    - 替代方案：讓 LLM 直接估熱量。放棄原因：GPT-4o 照片估熱量的 MAPE 約 36%（Fridolfsson et al., 2025），而且數值無法追溯；但 Open-KNEAD（2026）指出新一代 MLLM 直接估算已接近檢索管線，因此 W6 會把「純 LLM」列為基準方法實測，不預設它一定比較差。
2. **RAG + 規則，而不是微調**：營養資料庫會更新，用檢索比重新訓練好維護；份量與安全規則用表格管理，方便口試時說明。
    - 替代方案：Fine-tuned domain LLM、知識圖譜。放棄原因：需要大量標註資料，而且難以追溯來源。
3. **台灣資料優先**：檢索排序時台灣資料庫優先，USDA 補足西式與包裝食品。
4. **區間輸出 + 單次追問**：在準確度與使用者負擔之間取折衷（Trade-off 1，見 docs/01）。
5. **安全下限依性別區分：女性 1,200 kcal、男性 1,500 kcal**（Harvard Health Publishing, 2024：低於此值應在專業人員監督下進行）。性別未提供時先詢問；回答前暫用 1,200 kcal，避免對女性使用者誤報。
    - 替代方案：單一 1,200 kcal 下限。放棄原因：對男性過於寬鬆，男性長期吃 1,200–1,500 kcal 不會被提示。
    - 替代方案：依 BMR 的固定比例（例如 BMR × 0.8）。放棄原因：較難向使用者說明，也沒有公認的臨床門檻；列為 Future Work。
6. **語音輸入不列入 Proposal 範圍，放在 W8 的延伸目標**：Proposal 與評估集都以文字為準；只有 W1–W7 全部完成，才在 W8 加入 Whisper 前處理，並用 30 筆語音樣本另外回報辨識錯誤率。
    - 理由：台灣食物名稱（蚵仔煎、肉圓、地瓜球）的語音辨識錯誤會和熱量估算誤差混在一起，讓 W6 的評估無法分辨誤差來源。
    - 替代方案：W5 就做語音。放棄原因：會壓縮 W5 安全守門的實作時間，而安全守門是必繳的核心需求。
7. **台式料理庫的參考值採三層驗證**：
    1. **全部**：依食藥署資料庫以食材拆解計算，記錄食譜與份量來源。
    2. **至少 50 筆（10%）**：由兩位標註者各自獨立計算，回報一致性（兩者差距 ≤ 10% 的比例）；差距過大的項目由第三人仲裁。
    3. **至少 30 筆**：與連鎖業者公開的營養標示交叉比對（例如便利商店便當、連鎖手搖飲）。
    - 不安排營養師複核：本專題沒有可協助的營養師，驗證完全依靠上述三層，報告中如實說明這項限制。
8. **每日總量的區間用平方和開根號合併**：點估計直接相加，半寬取各筆半寬的平方和開根號。
    - 替代方案：各筆的 low、high 直接相加。放棄原因：這等於假設每一筆都同時偏高或偏低，一天記錄越多筆，區間就越寬，失去參考價值。
    - 風險：同一個人的份量誤差可能同方向（自報普遍低估）。因此 W6 會另外檢驗「每日層級」的 coverage；不足時改用較保守的合併方式，並更新本決定。
9. **未知食物的食材比例可以由 LLM 提議，但每 100 g 的營養數值仍來自資料庫**：料理庫沒有的菜（例如家常菜），由 LLM 列出食材與大約比例，再逐一到資料庫查數值。
    - 這是唯一讓 LLM 影響熱量的地方，所以該筆記錄一定標示「近似估算」，並套用較寬的區間。

    - 替代方案：查不到就拒絕記錄。放棄原因：使用者會因此漏記，而漏記本身就是已知的主要誤差來源。

5.10 風險與對策

- [台式料理份量差異大，例如一碗麵 400–700 g] → 建立份量對照表，區間依份量描述的模糊程度加寬。
- [食藥署資料庫以原料為主，熟食料理品項少] → 自建台式料理庫，以食材拆解加權計算，並標示為衍生資料。
- [區間太寬就失去參考價值] → 同時回報 coverage 與平均寬度，校準 `α`、`β`，並設半寬上限 `w_max`。
- [追問太多導致放棄] → 每項食物最多追問一次，並記錄追問率作為評估指標。
- [LLM 供應商收到飲食描述] → 送出前移除姓名等識別資訊；個人資料與日誌存在本機。
- [安全守門的誤報讓使用者反感] → 以 7 日資料判斷，並用非評判的語氣提示。
- [固定下限不適合所有人（例如高齡、孕婦、運動員）] → 回應中說明下限是一般成人的參考值，並建議特殊族群諮詢專業人員；不針對這些族群提供熱量目標。
- [沒有營養師複核，參考值可能有系統性偏差] → 以雙人獨立標註與業者營養標示交叉比對降低偏差，並在 Limitations 中說明。
- [資料建置約 110 小時，可能拖延時程] → 依「如果進度落後，依序縮減」的順序處理。
- [外部 API 或 LLM 暫時無法使用] → 來源逾時就略過並註明；LLM 無法使用時回覆「暫時無法記錄」，不寫入不完整的資料。

5.11 時程（W1–W8，共 33 項任務）

週	工作	任務數
W1	專案骨架與資料取得	4
W2	Domain Knowledge 規則與資料	4
W3	輸入處理與 Planner（①②③）	4
W4	檢索與分析（④⑤）	5
W5	決策、安全守門與輸出（⑥⑦⑧）	4
W6	評估資料與離線實驗	5
W7	使用者研究	3
W8	Final Handover	4
	合計	**33**

6. References

文獻 R1–R29

編號	文獻	查證來源
R1	Hua, A., Dhaliwal, M. P., Pullela, L., Burke, R., & Qin, Y. (2025). NutriBench: A dataset for evaluating large language models on nutrition estimation from meal descriptions. *ICLR 2025*. arXiv:2407.12843	ICLR proceedings、arXiv
R2	O'Hara, C., Kent, G., Flynn, A. C., Gibney, E. R., et al. (2025). An evaluation of ChatGPT for nutrient content estimation from meal photographs. *Nutrients*, 17(4), 607. https://doi.org/10.3390/nu17040607	PubMed、PMC11858203
R3	Fridolfsson, J., Sjöberg, E., Thiwång, M., & Pettersson, S. (2025). Performance evaluation of 3 large language models for nutritional content estimation from food images. *Current Developments in Nutrition*, 9(10), 107556.	PMC12513282
R4	Chen, Y. J., Chang, C. C., Hoang, Y. N., … Wei, P. H., & Chang, J. S. (2025). Customized multimodal Diabot-GPT-4o enhances accuracy of image-based dietary assessments in dietetic trainees in Taiwan: Validation against weighed food records. *American Journal of Clinical Nutrition*, 122(6), 1836–1849. https://doi.org/10.1016/j.ajcnut.2025.10.013	PubMed 41138916
R5	Jin, S., Zhang, J., Zhang, X., Tian, Z., Jiang, F., Yin, G., Lin, W., Liu, Y., & Yan, R. (2026). DiningBench: A hierarchical multi-view benchmark for perception and reasoning in the dietary domain. *ACL 2026* (Main). arXiv:2604.10425	arXiv
R6	Coburn, B., Yue, J., Ma, J., Raghavan, S., Vinod, G., & Zhu, F. (2026). Open-KNEAD: Knowledge-grounded nutrition estimation via agentic decomposition. arXiv:2607.12911	arXiv（預印本，尚未經同儕審查）
R7	Yang, Z., Khatibi, E., Nagesh, N., Abbasian, M., Azimi, I., Jain, R., & Rahmani, A. M. (2024). ChatDiet: Empowering personalized nutrition-oriented food recommender chatbots through an LLM-augmented framework. arXiv:2403.00781	arXiv
R8	Lo, F. P.-W., Qiu, J., Wang, Z., Chen, J., Xiao, B., Yuan, W., Giannarou, S., Frost, G., & Lo, B. (2024). Dietary assessment with multimodal ChatGPT: A systematic analysis. *IEEE Journal of Biomedical and Health Informatics*, 28(12), 7577–7587. https://doi.org/10.1109/JBHI.2024.3417280	PubMed 38900623
R9	Coburn, B., He, J., Rollo, M. E., Dhaliwal, S. S., Kerr, D. A., & Zhu, F. (2025). Comprehensive evaluation of large multimodal models for nutrition analysis: A new benchmark enriched with contextual metadata. arXiv:2507.07048（短版發表於 IEEE BHI 2025）	arXiv
R10	Požarnik Vavken, M., Ogrinc, M., Eftimov, T., & Koroušić Seljak, B. (2026). Evaluation of LLMs in retrieving food and nutritional context for RAG systems. arXiv:2603.09704	arXiv
R11	Dugas, K., Giroux, M.-A., Guerroudj, A., Leger, J., Rouhafzay, A., Rouhafzay, G., & Jbilou, J. (2026). Calorie-counting apps for monitoring and managing calorie intake in adults living with weight-related chronic diseases: Decade-long scoping review (2013–2024). *JMIR mHealth and uHealth*, 14, e64139. https://doi.org/10.2196/64139	PMC13085986；5.4 → 1.4 天的數據已在摘要中確認
R12	Evenepoel, C., Clevers, E., Deroover, L., Van Loo, W., et al. (2020). Accuracy of nutrient calculations using the consumer-focused online app MyFitnessPal: Validation study. *Journal of Medical Internet Research*, 22(10), e18237. https://doi.org/10.2196/18237	PubMed

編號	文獻	查證來源
R13	Chen, J., Berkman, W., Bardouh, M., Ng, C. Y. K., & Allman-Farinelli, M. (2019). The use of a food logging app in the naturalistic setting fails to provide accurate measurements of nutrients and poses usability challenges. *Nutrition*, 57, 208–216. https://doi.org/10.1016/j.nut.2018.05.003	PubMed 30184514；18% 與 1,863 kJ 已在摘要中確認
R14	World Health Organization. (2025, December 8). *Obesity and overweight* [Fact sheet]. https://www.who.int/news-room/fact-sheets/detail/obesity-and-overweight	who.int
R15	衛生福利部國民健康署。（2022）。新聞稿附件：18 歲以上國人三高及過重肥胖盛行率（資料來源：2017–2020 年國民營養健康狀況變遷調查）。https://mohw.gov.tw/dl-80876-5cf922a3-7c1e-47b8-9e88-f66c5be96106.html	已讀取原始附件，四個數字相符
R16	Zeevi, D., Korem, T., Zmora, N., et al. (2015). Personalized nutrition by prediction of glycemic responses. *Cell*, 163(5), 1079–1094. https://doi.org/10.1016/j.cell.2015.11.001	經典文獻
R17	Mifflin, M. D., St Jeor, S. T., Hill, L. A., Scott, B. J., et al. (1990). A new predictive equation for resting energy expenditure in healthy individuals. *American Journal of Clinical Nutrition*, 51(2), 241–247. https://doi.org/10.1093/ajcn/51.2.241	PubMed
R18	Hall, K. D., Sacks, G., Chandramohan, D., Chow, C. C., et al. (2011). Quantification of the effect of energy imbalance on bodyweight. *The Lancet*, 378(9793), 826–837. https://doi.org/10.1016/S0140-6736(11)60812-X	PubMed（期中稿誤植為 2012）
R19	Poslusna, K., Ruprich, J., de Vries, J. H., Jakubikova, M., et al. (2009). Misreporting of energy and micronutrient intake estimated by food records and 24 hour recalls, control and adjustment methods in practice. *British Journal of Nutrition*, 101(Suppl 2), S73–S85. https://doi.org/10.1017/S0007114509990602	PubMed
R20	Gardner, C. D., Trepanowski, J. F., Del Gobbo, L. C., Hauser, M. E., et al. (2018). Effect of low-fat vs low-carbohydrate diet on 12-month weight loss in overweight adults and the association with genotype pattern or insulin secretion: The DIETFITS randomized clinical trial. *JAMA*, 319(7), 667–679. https://doi.org/10.1001/jama.2018.0245	PubMed
R21	World Health Organization. (2025, December 1). *WHO issues global guideline on the use of GLP-1 medicines in treating obesity* [News release]. https://www.who.int/news/item/01-12-2025-who-issues-global-guideline-on-the-use-of-glp-1-medicines-in-treating-obesity	who.int
R22	衛生福利部食品藥物管理署。台灣地區食品營養成分資料庫。https://consumer.fda.gov.tw/Food/TFND.aspx	官方資料庫；使用時記錄版本
R23	U.S. Department of Agriculture, Agricultural Research Service. FoodData Central. https://fdc.nal.usda.gov/	官方資料庫
R24	Burke, L. E., Wang, J., & Sevick, M. A. (2011). Self-monitoring in weight loss: A systematic review of the literature. *Journal of the American Dietetic Association*, 111(1), 92–102. https://doi.org/10.1016/j.jada.2010.10.008	PubMed
R25	Ebbeling, C. B., Feldman, H. A., Klein, G. L., Wong, J. M. W., et al. (2018). Effects of a low carbohydrate diet on energy expenditure during weight loss maintenance: Randomized trial. *BMJ*, 363, k4583. https://doi.org/10.1136/bmj.k4583	PubMed（結果數字已核對）
R26	Hall, K. D., Chen, K. Y., Guo, J., Lam, Y. Y., et al. (2016). Energy expenditure and body composition changes after an isocaloric ketogenic diet in overweight and obese men. *American Journal of Clinical Nutrition*, 104(2), 324–333. https://doi.org/10.3945/ajcn.116.133561	PubMed（結果數字已核對）
R27	Koenders, P. G., & van Strien, T. (2011). Emotional eating, rather than lifestyle behavior, drives weight gain in a prospective study in 1562 employees. *Journal of Occupational and Environmental Medicine*, 53(11), 1287–1293. https://doi.org/10.1097/JOM.0b013e31823078a2	PubMed

編號	文獻	查證來源
R28	衛生福利部國民健康署。（2018）。*每日飲食指南手冊*（第二版）。https://www.hpa.gov.tw/Pages/EBook.aspx?nodeid=1208	國健署官網；三大營養素占總熱量比例：蛋白質 10–20%、脂質 20–30%、醣類 50–60%
R29	Harvard Health Publishing. (2024, April 3). *Calorie counting made easy*. https://www.health.harvard.edu/staying-healthy/calorie-counting-made-easy	原文確認：女性不低於 1,200、男性不低於 1,500 kcal，除非有專業人員監督

新增來源 N1–N6

編號	來源	等級
N1	Li, X., Yin, A., Choi, H. Y., Chan, V., Allman-Farinelli, M., & Chen, J. (2024). Evaluating the quality and comparative validity of manual food logging and artificial intelligence-enabled food image recognition in apps for nutrition care. *Nutrients*, 16(15), 2573. https://doi.org/10.3390/nu16152573 ；雪梨大學新聞稿（2024-08-29）	期刊論文（Crossref 已確認）
N2	Hengist, A., et al. (2026). 拍照熱量 App 準確度研究，發表於 American Society for Nutrition 年會 NUTRITION 2026；ScienceDaily（2026-07-26）、Newsweek、HealthDay（2026-07-27）報導	研討會摘要，尚未經完整同儕審查；第一作者以正式摘要為準
N3	Bort, J. (2026, March 2). MyFitnessPal has acquired Cal AI, the viral calorie app built by teens. *TechCrunch*. https://techcrunch.com/2026/03/02/myfitnesspal-has-acquired-cal-ai-the-viral-calorie-app-built-by-teens	科技媒體；營收與下載數由 MyFitnessPal 提供
N4	潘文涵（計畫主持人）。國民營養健康狀況變遷調查（106–109 年）成果報告。衛生福利部國民健康署委託研究計畫。第三章第九節「國人外食情形」，表 3.9.1，頁 162–163。https://www.hpa.gov.tw/Pages/ashx/GetFile.ashx?lang=c&type=1&sid=dbeb2e2da047472f9a8dd816d0b021ac	官方報告（已讀取原始 PDF；68.0% = 34.8 + 27.2 + 6.0）
N5	Bilen, A. B., Kalkan, G. E., & Yılmaz Önal, H. Y. (2026). Artificial intelligence diet plans underestimate nutrient intake compared to dietitians in adolescents. *Frontiers in Nutrition*, 13, 1765598. https://doi.org/10.3389/fnut.2026.1765598	期刊論文（Crossref 已確認）
N6	Liao, L.-L., Chang, L.-C., & Lai, I.-J. (2024). Assessing the quality of ChatGPT's dietary advice for college students from dietitians' perspectives. *Nutrients*, 16(12), 1939. https://doi.org/10.3390/nu16121939	期刊論文（PubMed 38931294 已確認）